

Trabalho Prático 2: Corretor Ortográfico

¹Alexandre Aparecido Scrocaro Junior R.A.: 2135485, ²Pedro Acácio Rodrigues R.A.: 2135655

Universidade Tecnológica Federal do Paraná – UTFPR

COCIC – Coordenação do Curso de Bacharelado em Ciência da Computação

Campo Mourão, Paraná, Brasil

¹alexandre.2001@alunos.utfpr.edu.br

²pedrorodrigues.2019@alunos.utfpr.edu.br

Resumo

Esse projeto tem como objetivo explorar uma solução para correções ortográficas por meio do uso de TRIEs. O uso dessa estrutura de dados possibilita análise ortográfica letra-a-letra de acordo com as regras especificadas e uma regra extra criada.

1. Modularização

Para a implementação desenvolvemos TADs para modularizar o projeto e assim ambos os participantes puderam desenvolver em conjunto, os TADs utilizados foram:

- TAD_Corretor:

Esse módulo foi criado para tratar das palavras incorretas e sugerir soluções.

arquivoParaLista: Lê o arquivo, percorre até o final selecionando seus caracteres e quando encontra uma palavra verifica se está incorreta e a adiciona na lista, após isso retorna a lista de palavras erradas.

PreencherTrieAux: Insere a lista de correções em uma trie.

regraUm: Insere um coringa (*) em cada uma das posições da String de forma alternada, chama a função TRIE_ChavesQueCasam para criar uma lista com todas as correções possíveis e assim preenche a trie correções.

regraDois: O tamanho da String é diminuído conforme os valores especificados pelo professor, chama função TRIE_ChavesComPrefixo com a nova String para criar uma lista com todas as correções possíveis e assim preenche a trie correções.

regraTres: Pega o maior prefixo da palavra passada, cria uma lista com todas as chaves que casam com esse prefixo, cria-se uma lista com o maior prefixo e preenche a trie com ele.

regraTeste: Alterna dois coringas entre as posições de uma palavra incorreta, verifica as chaves que casam com essa nova String e preenche a trie. Dessa forma é possível sugerir soluções para palavras que possuam 2 caracteres incorretos em posições aleatórias. Nesta regra, havia sido feita a mesclagem das regras 1 e 2, porém notamos que recriando a regra 1 de forma duplicada encontra-se melhores sugestões para palavras incorretas.

CorrigirOrtografia: A partir da lista com as palavras erradas, aplica-se as regras para cada palavra da lista, cria uma nova lista com as sugestões partindo da trie preenchida pelas regras, ordena-se a lista de sugestões conforme suas exigências e após isso a lista é impressa. Ao fim da função tem-se os resultados inseridos na tabela de análise.

- **TRIE:**

Esse módulo foi utilizado para conter as funções que manuseiam a estrutura de dados TRIE.

AT_Buscar: Preenche AT_Buscar_R para o início da busca e chama a função recursiva.

AT_Buscar_R: Busca nó a nó até completar a chave, ao final retorna o nó ou NULL para quando a palavra não existe na trie.

AT_Criar: Criação de um nó da trie;

AT_Inserir: Preenche AT_Inserir_R para o início da busca e chama a função recursiva e atualiza o tamanho da estrutura.

AT_Inserir_R: Insere na trie cada caractere contido na chave.

AT_Imprimir: Preenche AT_Imprimir_R para o início da busca e chama a função recursiva.

AT_Imprimir_R: Mostra a trie, delimitando o nível do nó (-) e apresenta o estado dele ('O' ou 'L').

AT_Limpa: Desaloca a trie.

ConstruirDicionario: Insere as palavras do arquivo dicionário.txt na trie.

- **TAD_FuncoesChave:**

Esse módulo foi implementado para tratar de funções que possuem relações diretas com a chave. Lembrando que todas as funções não recursivas criam uma lista.

TRIE_ChavesComPrefixo: Busca o prefixo na trie e passa o nó obtido para a função recursiva e retorna a lista resultante.

TRIE_ChavesComPrefixo_R: Realiza os casos base para verificar se a trie está vazia; de forma recursiva verifica os filhos do nó atual até obter as chaves com o prefixo passado.

TRIE_ChavesQueCasam: Adiciona um coringa (*) ao final do padrão passado, chama-se a função recursiva e ao final retorna a lista das chaves que casam.

TRIE_ChavesQueCasam_R: Verifica o caso base para a trie igual a NULL, recursivamente analisa todos os filhos do padrão passado e insere na lista todas as chaves que casam com esse padrão.

TRIE_ChaveMaiorPrefixoDe: Chama a função recursiva, verifica o maior prefixo da lista resultante através da função maiorPrefix e o retorna.

TRIE_ChaveMaiorPrefixoDe_R: Busca no dicionário a String passada, verifica recursivamente uma String com um caractere a menos que a anterior, e salva todos os prefixos possíveis em uma lista.

maiorPrefix: Verifica o maior prefixo possível da lista que seja uma palavra e o retorna.

- TAD_Lista:

A estrutura de dados escolhida para armazenar palavras incorretas, corretas e todas do texto foi a lista, enfim chaves. Também temos nesse TAD a criação das STRUCT Lista e do nó, neste TAD temos as seguintes funções.

criarLista: Criação de uma estrutura lista e de um nó vazio para onde a lista aponta.

atribuirPalavra: Insere uma palavra (chave) na estrutura.

imprimirLista: Mostra o conteúdo de todos os integrantes da estrutura.

bubbleSort: Utilizado para ordenação da estrutura, usado na lista de sugestões.

2. Análise

Fazendo uma análise das correções, vemos que as melhores sugestões seguem a regra 1. Por outro lado, a regra 2 tende a falhar em alguns casos apresentando palavras desnecessariamente grandes, a regra extra criada se mostra eficaz em palavras maiores com dois erros, porém quando se trata de menos caracteres suas sugestões são pouco precisas. Ao analisar a tabela obtida, vemos que o número médio de sugestões por palavra incorreta se mantém constante junto ao tempo de execução que apenas aumenta, quando o número de palavras cresce drasticamente

- Tabela 1:

	Total de palavras	Palavras incorretas	Número médio de sugestões por palavra incorreta	Tempo de execução (s)
casmurro1.txt	826	68	43	0.93
casmurro2.txt	530	46	32	0.451
casmurro3.txt	452	39	35	0.398
casmurro4.txt	797	57	59	0.979
memposthumas1.txt	697	98	30	0.662
memposthumas2.txt	529	45	26	0.386
memposthumas3.txt	563	46	55	0.865
casmurro_all.txt	2605	212	43	2.558
memposthumas_all.txt	1789	159	36	1.75
all.txt	4394	368	41	5.305

- Considerações adicionais:

Ao fazer alguns free's, dava erro dentro da biblioteca stdlib, então decidimos fazer somente outros com certeza que não fariam diferença, negativa, para o funcionamento do código.

3. Distribuição do projeto

O trabalho não foi dividido em partes para os dois alunos, ambos participaram de todas as etapas de produção do trabalho, sendo realizado da seguinte forma:

- Código: para a interpretação, elaboração da lógica e desenvolvimento dos arquivos(.c e .h), nos reunimos pelo aplicativo Discord usando chamadas de voz e compartilhamento de tela;
- Relatório: para escrever o presente documento, também fizemos uso do discord para chamadas de voz e da ferramenta online Docs, do google; desse modo conseguimos redigir o relatório de forma simultânea.